

Sprawozdanie z laboratorium nr 7

Inteligentne Metody Optymalizacji

Autorzy: Jakub Gołąb, Mariusz Hybiak

Zadanie 7. Własna metoda

Wprowadzenie

Celem zadania była próba poprawienia wcześniej zaimplementowanych algorytmów poprzez zastosowanie nowej metody.

Dla każdej instancji problemu zostały przeprowadzone testy dla 100 uruchomień algorytmu. Do czasu działania nie jest wliczany czas generacji rozwiązań startowych, ponieważ jest on jednorazowy - rozwiązania startowe można wygenerować raz i używać wielokrotnie.

Słowny opis metody

Jest to autorska metoda zainspirowana poprzednimi laboratoriami. Rozwiązania startowe nie są tutaj losowe. Początkowo jest generowana populacja 1000 rozwiązań. Dla każdej pary z nich sprawdzane są wspólne krawędzie. Następnie te wspólne krawędzie są zliczane i sortowane. 5% najczęściej występujących krawędzi służy do budowy rozwiązań startowych. Dalej rozwiązania te są rozbudowane poprzez dodawanie wierzchołków metodą greedy. Na tak powstałych pełnych cyklach uruchamiany jest algorytm ILS2 o zmiennym rozmiarze perturbacji. Jeśli perturbacja nie poprawia wyniku, to jest ona zwiększana. Jeśli w ciągu 10 iteracji nie udało się poprawić wyniku, to algorytm uruchamia lokalne przeszukiwanie. Ma to na celu optymalizację czasową działania algorytmu.

Pseudokod

```
wygeneruj 1000 rozwiązań startowych metodą LS greedy  
  
oblicz wspólne krawędzie dla każdej pary rozwiązań  
  
zliczaj wspólne krawędzie  
  
wybierz 5% najczęściej występujących krawędzi  
  
utwórz początek cyklu pierwszego z połowy krawędzi  
  
utwórz początek cyklu drugiego z drugiej połowy krawędzi  
  
dodaj wierzchołki metodą greedy uzupełniając cykl pierwszy  
  
dodaj wierzchołki metodą greedy uzupełniając cykl drugi  
  
zapamiętaj rozwiązanie startowe  
  
dopóki nie minie czas
```

```

uruchom ILS2 z perturbacją o zmiennym rozmiarze
jeśli perturbacja nie poprawia wyniku
    zwiększ perturbację o 0.05
jeśli w ciągu 10 iteracji nie udało się poprawić wyniku
    uruchom lokalne przeszukiwanie steepest
    zmniejsz perturbację o 0.05
jeśli wynik jest lepszy od najlepszego
    zapamiętaj wynik

```

Wyniki

```

.dataframe tbody tr th {
    vertical-align: top;
}


.dataframe thead th {
    text-align: right;
}

```

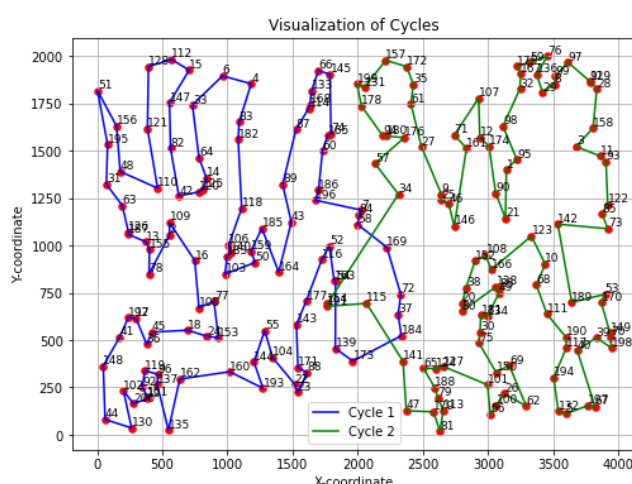
filename	min_time	mean_time	max_time	min_length	mean_length	max_length
kroA200.tsp	25.000386	25.040874	26.042522	31262.513284	31980.859761	33214.320204
kroB200.tsp	25.0	25.23375	27.042993	32617.154133	33291.298487	33402.594883

Najlepsze cykle z metody

kroA200



kroB200



Wnioski

- Metoda wymaga dużo czasu na generację rozwiązań startowych, ale jest to jednorazowe. Opierając się na tych danych można wielokrotnie uruchamiać algorytm w poszukiwaniu optymalnego rozwiązania.

- W niższym czasie udało się uzyskać wyniki porównywalne, a nawet lepsze (zwłaszcza dla instancji A), w porównaniu z innymi algorytmami.
- Algorytm zdaje się być stabilny w obrębie różnych instancji problemu.
- Można by spróbować zoptymalizować algorytm zmniejszając dopuszczalny czas działania.

Kod programu

Kod programu znajduje się pod [tym linkiem](#).